UPH Universitas Pelita Harapan

BEYOND ACADEMICS,
WE IMPACT LIVES

KECERDASAN ARTIFICIAL & SAINS DATA DASAR

Data Preparation & Visualisasi Data

DataFrame & Series • Data Cleaning • EDA • BI Tools • Visualisasi Data



Ardian Pamungkas, S.Kom., M.Kom.

AKREDITASI UNGGUL

Pelita Harapan Group

Apa yang Akan Kita Pelajari?

Sub-CPMK 2.1

Memahami konsep DataFrame & Series, serta melakukan data cleaning: missing values, duplicates, dan transformasi tipe data.

Sub-CPMK 2.2

Melakukan akuisisi & pembersihan data menggunakan Python (pandas), serta eksplorasi data secara interaktif dengan Jupyter Notebook.

Sub-CPMK 2.3

Membuat visualisasi data yang sesuai dengan tujuan analisis — memilih jenis chart yang tepat untuk pesan yang tepat.

Mengapa Data Preparation Penting?

60–80%

estimasi waktu analis data yang dihabiskan untuk data preparation

- Analogi: data mentah = bahan masakan dari pasar — harus dicuci & dipotong dulu sebelum dimasak (dianalisis).
- Data kotor → laporan salah → keputusan bisnis tidak valid ("garbage in, garbage out").
- Data organisasi berasal dari banyak sistem (ERP, CRM, POS, IoT) dengan format berbeda-beda — perlu disatukan & dibersihkan.
- Data preparation adalah implementasi teknis dari data quality: accuracy, completeness, consistency.

KONSEP DASAR

DataFrame & Series

Series

Struktur data 1 dimensi.
Mirip satu kolom tunggal, tiap elemen punya label/index.

Contoh: daftar nilai UTS mahasiswa dengan nama sebagai index.

DataFrame

Struktur data 2 dimensi (baris x kolom).
Analogi: tabel Excel / tabel database relasional.

Setiap kolom pada DataFrame sebenarnya adalah sebuah Series.

PRAKTIK 1

Indexing pada DataFrame & Series

```
import pandas as pd

df = pd.DataFrame({
    'nama': ['Andi','Budi','Citra','Dewi'],
    'nilai_uts': [85, 90, 78, 92],
    'jurusan': ['SI','SI','TI','SI']
})

df['nilai_uts']                    # akses 1 kolom -> Series
df.loc[0]                          # akses baris via LABEL index
df.iloc[0:2]                       # akses baris via POSISI (slicing)
df.loc[df['jurusan'] == 'SI']      # boolean indexing / filtering
```

.loc[ ] → berbasis LABEL **.iloc[ ]** → berbasis POSISI **Boolean indexing** → filtering data (paling sering dipakai saat EDA)

DATA CLEANING

Missing Values: Konsep & Strategi

Missing value = data yang tidak tersedia pada suatu observasi (di pandas: NaN / None). Penyebab umum: sensor gagal, formulir tidak lengkap, error integrasi antar sistem.

Strategi	Kapan Digunakan	Trade-off
Hapus baris (dropna)	Missing sedikit (<5%) & random	Kehilangan data lain di baris tsb.
Imputasi mean/median	Data numerik	Mean sensitif ke outlier
Imputasi modus	Data kategorikal	Bisa bias jika 1 kategori dominan
Kategori "Unknown"	Missing punya makna bisnis	Tidak semua algoritma mendukung

PRAKTIK 2

Menangani Missing Values dengan Pandas

```
import pandas as pd, numpy as np

df = pd.DataFrame({
    'nama': ['Andi','Budi','Citra','Dewi','Eka'],
    'nilai': [85, np.nan, 78, np.nan, 90],
    'kota': ['Jakarta','Bandung', None, 'Jakarta','Surabaya']
})

df.isnull().sum()                    # jumlah missing per kolom
df.dropna()                          # hapus baris ber-missing value
df['nilai'] = df['nilai'].fillna(df['nilai'].median())   # imputasi median
df['kota']  = df['kota'].fillna(df['kota'].mode()[0])     # imputasi modus
```

DATA CLEANING

Duplicate Data & Transformasi Tipe Data

Duplicate Data

Baris identik yang muncul >1 kali, akibat input berulang atau penggabungan data.

```
df.duplicated()
df.drop_duplicates(subset=['id'])
```

Hati-hati: pembelian sama 2x di hari berbeda BUKAN duplikat, itu transaksi sah.

Transformasi Tipe Data

Data dari sumber luar sering salah tipe (angka terbaca teks, tanggal terbaca string).

```
pd.to_datetime(df['tanggal'])
df['harga'].astype(int)
df['status'].astype(bool)
```

CRITICAL THINKING

Strategi Cleaning Bergantung Tujuan Analisis

Kasus A — Laporan Keuangan

Data harus 100% akurat. Missing value pada nominal transaksi WAJIB diverifikasi manual atau dihapus — tidak boleh diimputasi.

Kasus B — Model Prediksi Churn

Menghapus baris mengurangi data latih secara signifikan. Imputasi, atau menjadikan "missing" sebagai fitur, justru menguntungkan performa model.

Prinsip: selalu tanyakan “cleaning ini untuk tujuan apa?” sebelum memilih teknik.

Exploratory Data Analysis (EDA)

- EDA = proses “mengenal” data sebelum dianalisis lebih lanjut.
- Mencakup: ringkasan statistik, distribusi data, hubungan antar variabel, deteksi outlier/anomali.
- Dipopulerkan oleh John Tukey (1977), tetap menjadi tahap wajib dalam pipeline data science modern.
- Mencegah kesalahan interpretasi & bias analisis sebelum membangun kesimpulan atau model.

TAHAPAN EDA

Univariate → Bivariate → Multivariate

1

Univariate

Analisis 1 variabel: distribusi, rata-rata, sebaran.

→

2

Bivariate

Hubungan 2 variabel: korelasi, cross-tab.

→

3

Multivariate

Hubungan banyak variabel sekaligus.

PRAKTIK 3

EDA dengan Pandas

```
df = pd.read_csv('data_penjualan.csv')

df.info()                        # struktur & tipe data
df.describe()                    # statistik deskriptif
df['kategori_produk'].value_counts()      # distribusi kategorikal

df[['harga','jumlah_terjual']].corr()          # korelasi
df.groupby('kategori_produk')['jumlah_terjual'].mean()

Q1, Q3 = df['harga'].quantile([0.25, 0.75])
IQR = Q3 - Q1
outlier = df[(df['harga'] < Q1-1.5*IQR) | (df['harga'] > Q3+1.5*IQR)]
```

PERANGKAT ANALISIS

EDA Interaktif dengan Jupyter Notebook

Aspek	Jupyter Notebook (lokal)	Google Colab (cloud)
Instalasi	Perlu install Python + Jupyter (mis. via Anaconda)	Tanpa instalasi, langsung jalan di browser
Eksekusi	Per-cell, hasil & plot tampil langsung di bawah cell	Sama — per-cell, berbasis file .ipynb
Sumber daya	Memakai resource komputer sendiri	Tersedia GPU/TPU gratis (terbatas)
Kolaborasi & sharing	Export ke .html/.pdf, share file .ipynb	Share real-time seperti Google Docs

Keunggulan notebook untuk EDA: kode, hasil (tabel/angka), visualisasi, dan catatan analisis (Markdown) berada dalam satu dokumen — memudahkan eksplorasi data secara bertahap.

ALUR KERJA

Alur Kerja EDA dengan Notebook



VISUALISASI DATA

Memilih Jenis Visualisasi yang Tepat

Tujuan Analisis	Chart yang Disarankan
Melihat tren waktu	Line chart
Membandingkan kategori	Bar / Column chart
Melihat proporsi (kategori sedikit)	Pie / Donut chart
Melihat distribusi 1 variabel	Histogram / Box plot
Hubungan 2 variabel numerik	Scatter plot
Hubungan banyak variabel	Heatmap korelasi

Visualisasi bukan soal cantik

Visualisasi yang baik adalah yang paling efektif menyampaikan insight ke audiens.

Hindari:

- Pie chart untuk >6 kategori
- Sumbu Y bar chart tidak dari 0 (misleading)
- Chart junk / dekorasi berlebihan

UPH Universitas Pelita Harapan

BEYOND ACADEMICS, WE IMPACT LIVES

PRAKTIK 4

Visualisasi dengan Matplotlib & Seaborn

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns

np.random.seed(42)

data = {
    'tanggal': pd.date_range(start='2024-01-01', periods=120,
freq='D'),
    'kategori_produk': np.random.choice(
        ['Elektronik', 'Pakaian', 'Makanan', 'Kecantikan'],
        size=120
    ),
    'jumlah_terjual': np.random.randint(1, 50, size=120),
    'harga': np.random.randint(10000, 500000, size=120),
}

df = pd.DataFrame(data)

df['tanggal'] = pd.to_datetime(df['tanggal'])

df['bulan'] = df['tanggal'].dt.month_name()

urutan_bulan = [
    'January', 'February', 'March', 'April',
    'May', 'June', 'July', 'August',
    'September', 'October', 'November', 'December'
]
df['bulan'] = pd.Categorical(
 df['bulan'],
 categories=urutan_bulan,
 ordered=True
)
```

```
sns.set_theme(style='whitegrid')

plt.figure(figsize=(15, 12))

plt.subplot(3, 2, 1)

df.groupby('bulan', observed=False)['jumlah_terjual'].sum().plot(
    kind='line',
    marker='o',
    color='b'
)

plt.title('Total Terjual per Bulan')
plt.xlabel('Bulan')
plt.ylabel('Jumlah Terjual')
plt.xticks(rotation=45)

plt.subplot(3, 2, 2)

sns.barplot(
    data=df,
    x='kategori_produk',
    y='jumlah_terjual',
    estimator=sum,
    errorbar=None,
 palette='viridis'
)

plt.title('Total Terjual per Kategori Produk')
plt.xlabel('Kategori Produk')
plt.ylabel('Total Jumlah Terjual')

plt.subplot(3, 2, 3)
sns.histplot(
 df['harga'],
 bins=20,
 kde=True,
 color='teal'
)
```

```
plt.title('Distribusi Harga Produk')
plt.xlabel('Harga')
plt.ylabel('Frekuensi')

plt.subplot(3, 2, 4)

sns.scatterplot(
    data=df,
    x='harga',
    y='jumlah_terjual',
    hue='kategori_produk',
    style='kategori_produk',
    s=70
)

plt.title('Harga vs Jumlah Terjual')
plt.xlabel('Harga')
plt.ylabel('Jumlah Terjual')


plt.subplot(3, 2, 5)

numeric_df = df.select_dtypes(include='number')

sns.heatmap(
    numeric_df.corr(),
    annot=True,
    cmap='coolwarm',
    fmt='.2f'
)
plt.title('Heatmap Korelasi Variabel Numerik')

plt.tight_layout()
plt.show()
```

STUDI KASUS & AKTIVITAS KELAS

Studi Kasus: Divisi Marketing Kampus

Data pendaftar dari 3 kanal (online, walk-in, agen): ada duplikat lintas kanal, missing value nilai rata-rata (jalur walk-in), dan 3 format tanggal berbeda.

- Rancang strategi cleaning untuk tiap masalah + alasannya
- Tentukan 3 pertanyaan EDA untuk tim marketing
- Rancang 1 visualisasi paling tepat untuk menjawabnya

Live coding bersama

Group case analysis

UPH Universitas Pelita Harapan

BEYOND ACADEMICS,
WE IMPACT LIVES



THANK YOU

Ardian Pamungkas, S.Kom., M.Kom.

Pelita Harapan Group