UPH Universitas Pelita Harapan

BEYOND ACADEMICS,
WE IMPACT LIVES

KECERDASAN ARTIFISIAL DAN SAINS DATA DASAR

Mengajari mesin menemukan pola dari data yang sudah disiapkan

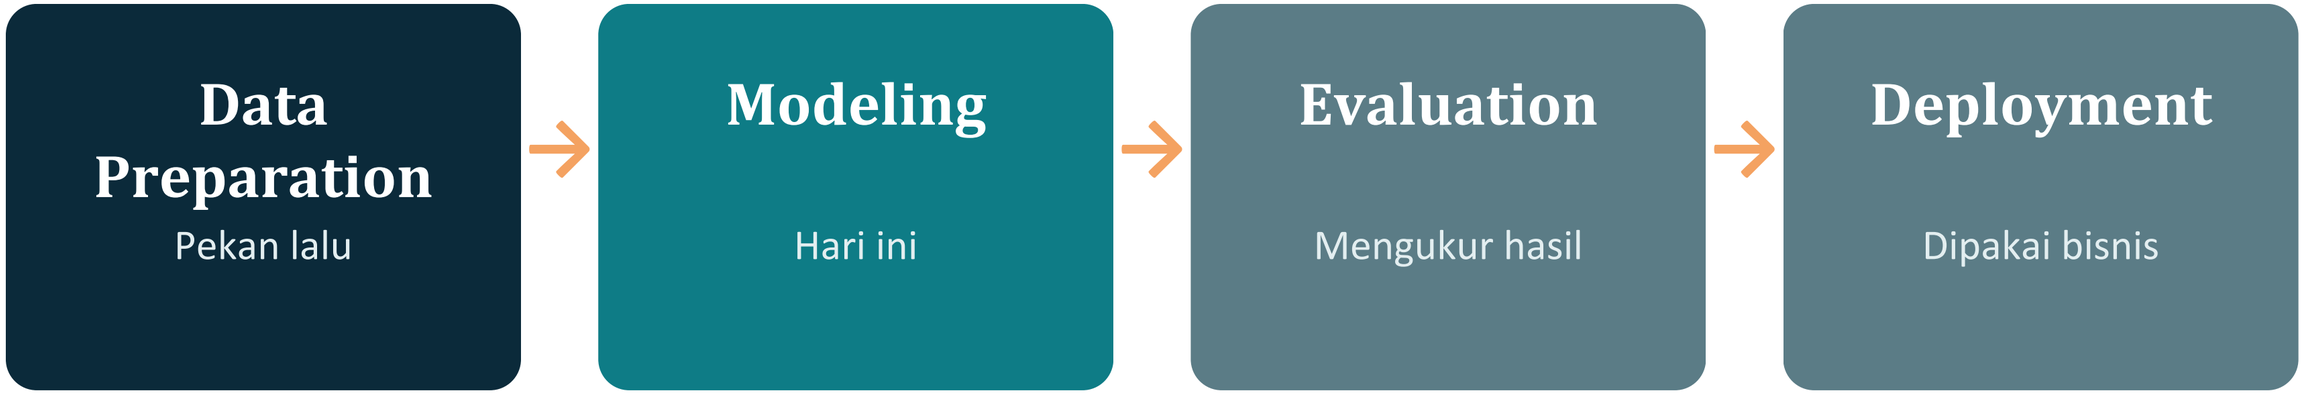


Ardian Pamungkas, S.Kom., M.Kom.

AKREDITASI UNGGUL

Pelita Harapan Group

Dari Data Preparation ke Modeling



Pesan utama: model adalah fungsi yang belajar memetakan input (fitur) ke output (target). Data bersih → pola yang dipelajari lebih benar.

Tiga Cara Mesin Belajar

Supervised

Data berlabel. Klasifikasi (lulus/tidak) dan regresi (prediksi penjualan).

Contoh: prediksi churn pelanggan.

Unsupervised

Tanpa label. Mencari struktur tersembunyi, mis. clustering.

Contoh: segmentasi pelanggan retail.

Reinforcement

Agen belajar lewat reward dan penalti.

Contoh: optimasi rute gudang dan rekomendasi dinamis.

Alur Training dan Testing

1. **Tentukan target**
2. **Split data 80/20**
3. **Training**
4. **Validasi**
5. **Testing**

Overfitting

Terlalu hafal data latih, gagal pada data baru.

Underfitting

Terlalu sederhana, pola belum tertangkap.

Memilih Algoritma

Algoritma	Jenis	Kelebihan	Kekurangan
Regresi Linear/Logistik	Supervised	Sederhana, mudah dijelaskan	Sulit untuk pola non-linear
Decision Tree	Supervised	Visual, mudah ditafsirkan	Rawan overfitting
Random Forest	Supervised	Akurat, tahan noise	Sulit dijelaskan
k-Means	Unsupervised	Cepat untuk segmentasi	Perlu menentukan nilai k

Mengevaluasi Model

TP Benar positif	**FN** Salah negatif
FP Salah positif	**TN** Benar negatif

Accuracy — Prediksi benar dibanding seluruh data

Precision — Dari yang diprediksi positif, berapa yang benar

Recall — Dari yang sebenarnya positif, berapa yang tertangkap

F1-score — Keseimbangan precision dan recall

Hands-on: Model Pertama

```
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)

model = DecisionTreeClassifier(max_depth=3)
model.fit(X_train, y_train)

pred = model.predict(X_test)
print(accuracy_score(y_test, pred))
```

Split

Data uji dipisah agar penilaian jujur.

fit()

Tahap model belajar dari data latih.

predict()

Model diuji pada data yang belum dilihat.

Membandingkan Beberapa Model

```
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import cross_val_score

models = {
  "Logistic": LogisticRegression(max_iter=1000),
  "RandomForest": RandomForestClassifier(),
}
for name, m in models.items():
    skor = cross_val_score(m, X, y, cv=5,
                           scoring="f1")
    print(name, skor.mean().round(3))
```

Cross-validation

Evaluasi 5 kali, hasil lebih andal.

Metrik F1

Cocok bila kelas tidak seimbang.

Baseline

Mulai sederhana, bandingkan bertahap.

Pipeline dan Tuning

```
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import GridSearchCV

pipe = Pipeline([
  ("scale", StandardScaler()),
  ("clf", RandomForestClassifier()),
])
grid = GridSearchCV(
  pipe, {"clf__max_depth": [3, 5, None]},
  cv=5, scoring="f1")
grid.fit(X_train, y_train)
print(grid.best_params_)
```

Pipeline

Preprocessing dan model satu alur.

Hyperparameter

Pengaturan model yang dicari otomatis.

Leakage

Data uji tidak boleh ikut memengaruhi training.

Jebakan dan Etika Modeling

Data Leakage

Informasi dari data uji atau masa depan bocor ke training, hasil tampak bagus tetapi gagal di dunia nyata.

Bias dan Fairness

Data historis yang bias menghasilkan keputusan yang bias. Audit performa per kelompok.

Explainability

Keputusan penting harus bisa dijelaskan kepada pengguna dan pemangku kepentingan.

Studi Kasus dan Diskusi

Kasus: Prediksi Drop-out

Fitur: IPK, kehadiran, aktivitas LMS, status biaya. Target: berisiko drop-out atau tidak. Data sudah bersih dari tahap Data Preparation.

Pertanyaan diskusi

- Algoritma apa yang Anda pilih, dan mengapa?
- Mana lebih berbahaya: salah menandai atau melewatkan mahasiswa berisiko?
- Apa risiko etis memakai prediksi ini?

Kesimpulan: data bersih + algoritma yang tepat + evaluasi yang jujur = model yang berguna.

Aktivitas Kelas dan Tugas

Aktivitas di Kelas

- Jalankan model dasar pada dataset kelas
- Ubah parameter, catat perubahan hasil
- Diskusi kelompok: model mana dipilih dan mengapa

Tugas Mini Project

- Pilih dataset hasil Data Preparation
- Bandingkan minimal 2 algoritma
- Evaluasi dengan metrik yang sesuai
- Tulis analisis kelebihan, kekurangan, dan risiko

UPH Universitas Pelita Harapan

BEYOND ACADEMICS,
WE IMPACT LIVES



UPH AKREDITASI UNGGUL

Pelita Harapan Group