UPH Universitas Pelita Harapan

BEYOND ACADEMICS,
WE IMPACT LIVES

KECERDASAN ARTIFISIAL & SAINS DATA DASAR

SUPERVISED LEARNING & REGRESSION



Ardian Pamungkas, S.Kom., M.Kom.

AKREDITASI UNGGUL

Pelita Harapan Group

Setelah pertemuan ini, mahasiswa mampu...

Sub-CPMK 3.1: mengukur kinerja model AI dengan metrik evaluasi yang tepat.

- Menjelaskan kapan masalah membutuhkan regresi.
- Membedakan Linear, Polynomial, Ridge, dan Lasso.
- Membangun empat model regresi dengan Python.
- Menghitung MAE, MSE, RMSE, dan R^2.
- Memilih model berdasarkan bukti evaluasi.

UPH Universitas Pelita Harapan

BEYOND ACADEMICS,
WE IMPACT LIVES

150 menit: pahami → praktikkan → evaluasi

Perkuliahan sinkronus dengan belajar terbimbing dan simulasi modeling.

01

Teori & konsep

60 menit

Konsep regresi, regularisasi, under/overfitting, metrik evaluasi

02

Tutorial Python

60 menit

Dataset, training, prediksi, evaluasi & visualisasi

03

Simulasi mandiri

30 menit

Kuis, eksperimen parameter, diskusi & penilaian

Apa itu supervised learning?

Model mempelajari pasangan input (X) dan target (y) dari data berlabel.

01

DATA

Fitur X dan target y

02

LATIH MODEL

Temukan hubungan/pola

03

PREDIKSI

Hasil ŷ pada data baru

Contoh: BMI (X) → model regresi → skor target (ŷ).

Regresi ≠ klasifikasi

Bentuk target menentukan jenis persoalan yang akan diselesaikan.

REGRESI

Output: nilai numerik

Contoh: harga Rp725 juta, skor 158, suhu 29,5 °C.

KLASIFIKASI

Output: kategori/kelas

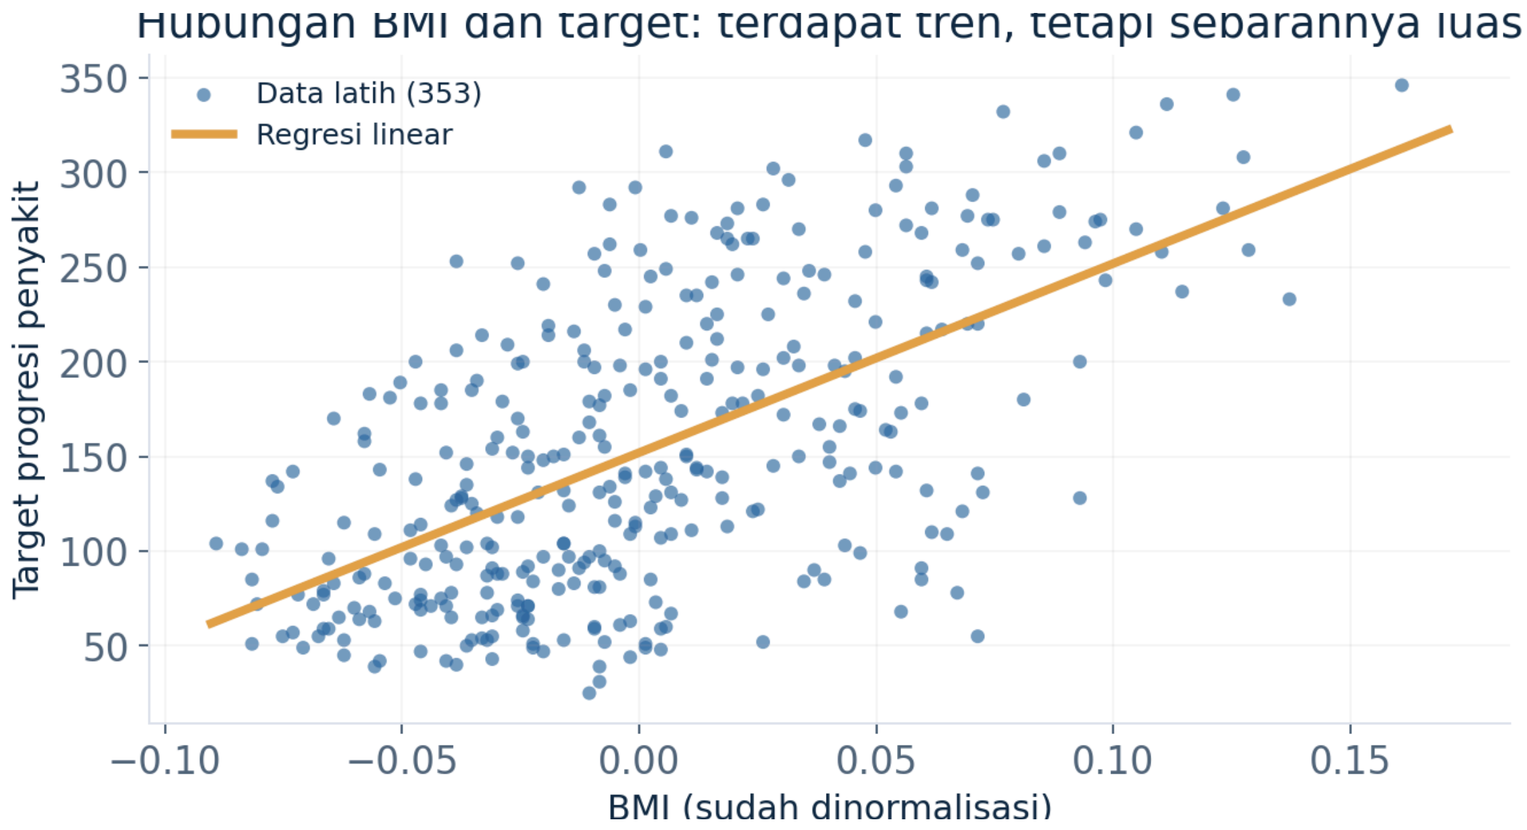
Contoh: spam/bukan spam, kategori rendah/sedang/tinggi.

Pertanyaan kelas: “Memperkirakan jumlah penjualan bulan depan” termasuk jenis apa?

LINEAR REGRESSION

Garis terbaik untuk hubungan linear

Model mencari kombinasi intercept dan slope yang cocok dengan data.



Intuisi

Setiap titik = observasi.

Garis = prediksi rata-rata model berdasarkan fitur BMI.

Linear Regression: pahami koefisien

Model sederhana memprediksi target melalui satu fitur.

$$\hat{y} = \beta_0 + \beta_1 x$$

β_0 — Intercept

Prediksi saat x = 0.

β_1 — Slope

Perubahan prediksi per 1 unit x.

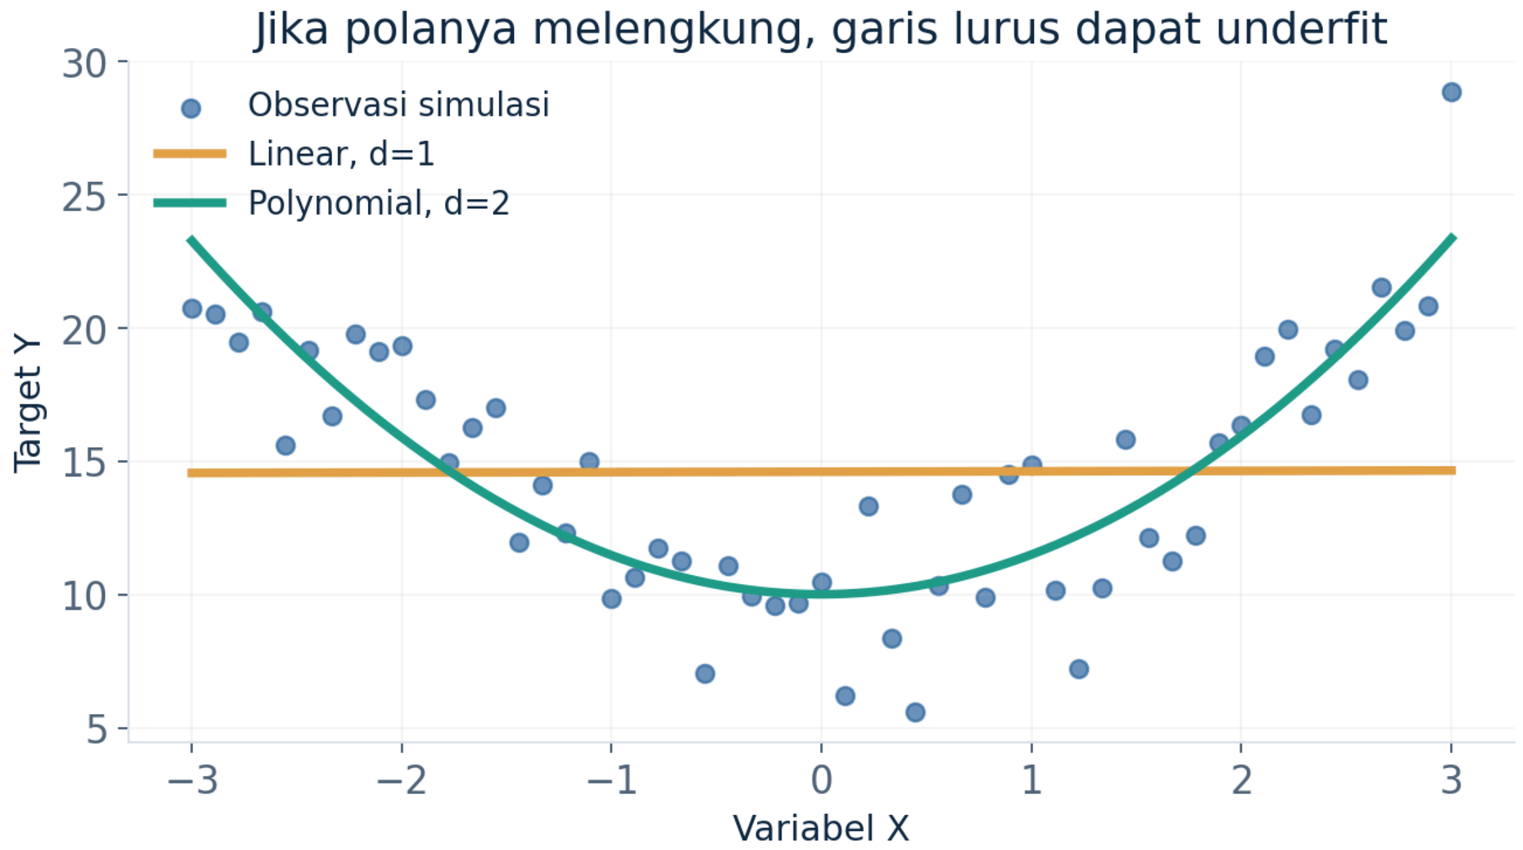
$\hat{y}$ — Prediksi

Nilai keluaran dari model.

POLYNOMIAL REGRESSION

Ketika garis lurus tidak cukup

Tambahan fitur x^2, x^3, dan seterusnya memungkinkan kurva.



Derajat 2

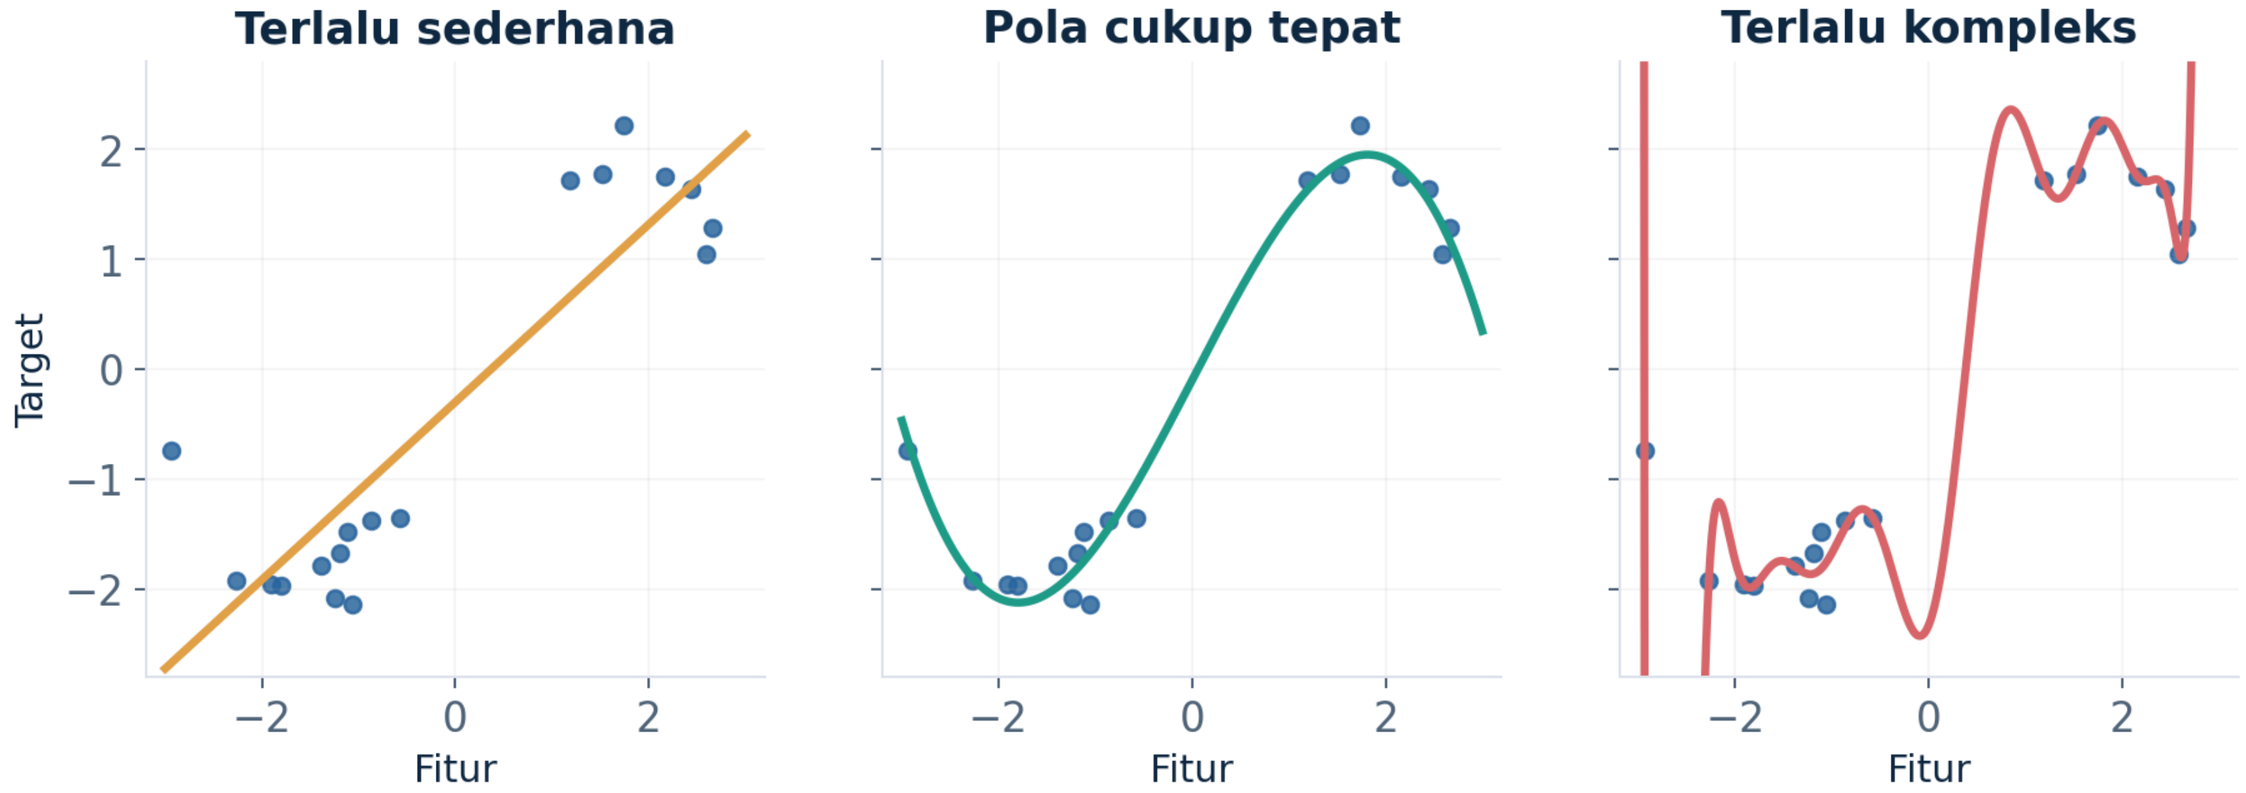
$\hat{y} = \beta_0 + \beta_1 x + \beta_2 x^2$

Model tetap linear terhadap koefisien β.

KOMPLEKSITAS

Underfitting vs good fit vs overfitting

Model fleksibel belum tentu memberi prediksi terbaik pada data baru.



POLA TAK TERTANGKAP

GENERALISASI

MENGIKUTI NOISE

DUA TEKNIK

Ridge (L2) dan Lasso (L1)

Keduanya mengecilkan koefisien, tetapi efeknya berbeda.

RIDGE

Penalti: $\alpha \Sigma \beta_j^2$

Koefisien dikecilkan.

Bermanfaat saat fitur saling berkorelasi.

LASSO

Penalti: $\alpha \Sigma |\beta_j|$

Sebagian koefisien bisa menjadi nol.

Dapat membantu seleksi fitur.

α MENGATUR KEKUATAN REGULARISASI

MENGHITUNG ERROR

Contoh: aktual vs prediksi

Semua perhitungan dimulai dari selisih y dan ŷ.

Observasi	Aktual	Prediksi	|Error|	Error²
1	70	72	2	4
2	80	78	2	4
3	90	87	3	9
4	100	103	3	9
TOTAL	—	—	**10**	**26**

Gunakan contoh ini untuk MAE, MSE, RMSE, dan R^2.

ERROR METRICS

MAE dan MSE: dua cara menghukum error

Keduanya lebih baik bila nilainya semakin mendekati nol.

MAE — Mean Absolute Error

$$MAE = \Sigma |y - \hat{y}| / n$$

Contoh: 10 / 4 = 2,5

Interpretasi: rata-rata besar kesalahan absolut.

MSE — Mean Squared Error

$$MSE = \Sigma (y - \hat{y})^2 / n$$

Contoh: 26 / 4 = 6,5

Kesalahan besar lebih dipenalti.

ERROR METRICS

RMSE dan R^2: ukuran pelengkap

RMSE kembali ke satuan target; R^2 mengukur penjelasan variasi.

RMSE — Root MSE

RMSE = √MSE

Contoh: √6,5 ≈ 2,55

Lebih besar pada error ekstrem dibanding MAE.

R^2 — Coefficient of Determination

$R^2 = 1 - SSE/SST$

Contoh: 1 – 26/500 = 0,948

Bisa negatif pada data uji.

EVALUASI ADIL

Pisahkan train, validasi, dan test

Model harus dinilai pada data yang tidak dipakai melatihnya.

TRAIN

Belajar parameter

70%

VALIDASI

Memilih konfigurasi

15%

TEST

Evaluasi akhir

15%

Untuk demo awal: train/test 80/20. Untuk memilih hyperparameter: tambah validasi silang pada train.

Universitas Pelita Harapan

BEYOND ACADEMICS, WE IMPACT LIVES

DATASET PRAKTIK

Dataset Diabetes dari Scikit-learn

Dataset edukasi untuk regresi; bukan sistem diagnosis medis.

442
Observasi
Jumlah data

10
Fitur numerik
Tersedia untuk praktik lanjutan

1
Fitur utama
BMI untuk visualisasi 2D

Target

Ukuran kuantitatif progresi penyakit satu tahun setelah baseline.

Fitur BMI telah dinormalisasi; jangan dibaca sebagai kg/m² mentah.

PYTHON • LANGKAH 1

Import dan membaca data

Tujuan: memastikan fitur, target, dan struktur dataset dipahami.

PYTHON

```
import pandas as pd
from sklearn.datasets import load_diabetes

data = load_diabetes(as_frame=True)
df = data.frame
print(df.shape)       # (442, 11) termasuk target
print(df[['bmi', 'target']].head())
```

Output: total 442 baris, 10 fitur, dan 1 kolom target.

PYTHON • LANGKAH 2

Memisahkan X, y, train, dan test

Bandingkan semua model menggunakan test set yang sama.

PYTHON

```
from sklearn.model_selection import train_test_split

X = df[['bmi']]
y = df['target']
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=42
)
print(len(X_train), len(X_test))  # 353, 89
```

Pertanyaan: mengapa random_state perlu ditetapkan?

PYTHON • LANGKAH 3

Baseline: Linear Regression

Mulai dari model yang sederhana sebelum mencoba yang kompleks.

PYTHON

```
from sklearn.linear_model import LinearRegression

linear = LinearRegression()
linear.fit(X_train, y_train)
y_pred = linear.predict(X_test)

print('Intercept:', linear.intercept_)
print('Slope:', linear.coef_[0])
```

BASELINE = PEMBANDING AWAL

PYTHON • LANGKAH 4

Polynomial Regression dalam pipeline

Coba degree = 2, lalu bandingkan degree = 5.

PYTHON

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import PolynomialFeatures
from sklearn.linear_model import LinearRegression

poly2 = make_pipeline(
    PolynomialFeatures(degree=2, include_bias=False),
    LinearRegression()
)
poly2.fit(X_train, y_train)
```

Ubah degree=2 menjadi degree=5; amati RMSE training & testing.

PYTHON • LANGKAH 5

Ridge dan Lasso: regularisasi

Gunakan StandardScaler di dalam pipeline.

PYTHON

```
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import Ridge, Lasso

ridge = make_pipeline(StandardScaler(), Ridge(alpha=1.0))
lasso = make_pipeline(
    StandardScaler(), Lasso(alpha=1.0, max_iter=10000)
)

ridge.fit(X_train, y_train)
lasso.fit(X_train, y_train)
```

PYTHON • LANGKAH 6

Hitung metrik evaluasi model

Empat ukuran kinerja pada prediksi data test.

PYTHON

```
import numpy as np
from sklearn.metrics import (
    mean_absolute_error, mean_squared_error, r2_score
)

mae = mean_absolute_error(y_test, y_pred)
mse = mean_squared_error(y_test, y_pred)
rmse = np.sqrt(mse)
r2 = r2_score(y_test, y_pred)
print(mae, mse, rmse, r2)
```

HASIL EKSPERIMEN

Bagaimana hasil tiap model?

Hasil benar-benar dihitung: random_state=42, test=20%, BMI sebagai satu fitur.

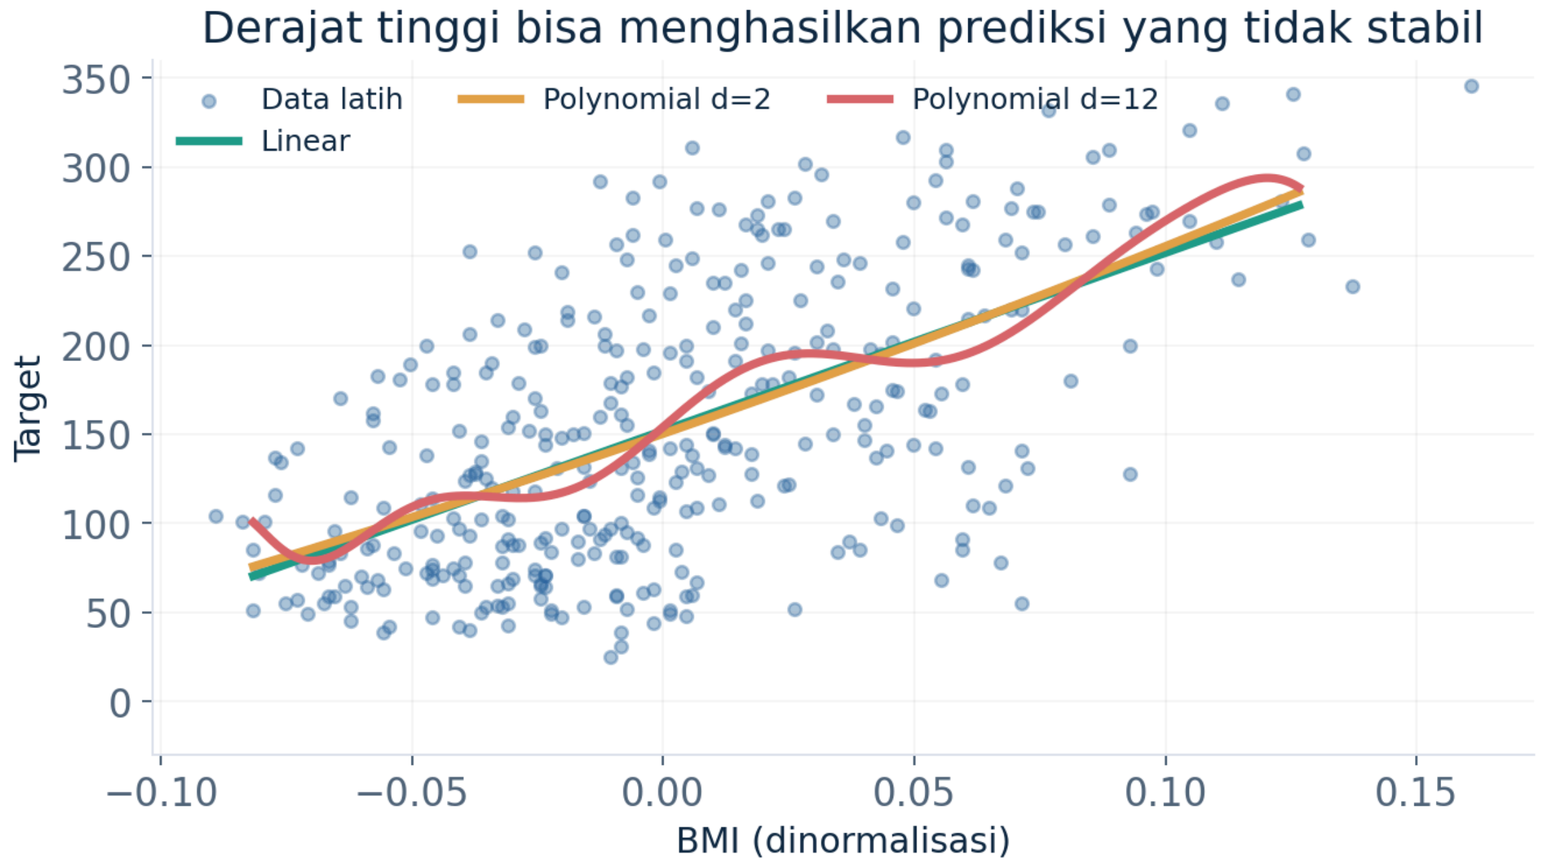
Model	MAE	MSE	RMSE	R^2
Linear	52.26	4061.83	63.73	0.233
Polynomial 2	52.38	4085.03	63.91	0.229
Polynomial 5	51.88	4085.85	63.92	0.229
Ridge (α=1)	52.26	4058.72	63.71	0.234
Lasso (α=1)	**52.26**	**4039.47**	**63.56**	**0.238**

Pada eksperimen ini Lasso memiliki RMSE terendah, tetapi selisihnya kecil.

VISUALISASI

Bandingkan bentuk prediksi

Model polynomial derajat tinggi bisa terlihat sangat berbeda.



Amati

Perubahan bentuk kurva terutama di daerah dengan data jarang.

Sinyal overfitting perlu diuji pada test.

TUGAS KELAS • 15 MENIT

Mini-project: bandingkan hasil prediksi

Kerjakan individu atau berpasangan menggunakan notebook yang sama.

- Ubah Polynomial degree menjadi 2 dan 5.
- Ubah alpha Ridge/Lasso menjadi 0,1; 1; dan 10.
- Buat tabel MAE, RMSE, dan R^2 pada test set yang sama.
- Pilih model terbaik menurut RMSE; jelaskan keterbatasannya.

Output: notebook + tabel model + satu paragraf interpretasi.

UPH Universitas Pelita Harapan

BEYOND ACADEMICS,
WE IMPACT LIVES



THANK YOU

Ardian Pamungkas, S.Kom., M.Kom.

Pelita Harapan Group